

Sentinel v3 — Thiết kế thực nghiệm bám sát draft FSE-2027-15

Sep 27, 2026 · @truong

v3 dựng lại Sentinel và AuditGame-SE theo đúng chữ của draft FSE-2027-15 (bản 07/09/2026). Mọi chỗ lệch chữ đều có bằng chứng. Mọi số dự phóng của draft được kiểm như một giả thuyết đã tiền đăng ký: số có thể không đẹp, nhưng số không có bằng chứng thì không được dùng.

Phạm vi

v3 là nền của cả bài báo viết lại bám draft lẫn luận văn. Ngày 27/09 đã chốt không nộp FSE ngày 02/10; bài v2 (khung bản đồ regime) chỉ còn là tài liệu tham chiếu.

- **Mục tiêu 1:** tái hiện đủ Table 1, Table 2, Table 3, Figure 3 và §10.2–§10.6 của draft, đúng hàng, đúng cột; cột dự phóng đặt cạnh cột đo.
- **Mục tiêu 2:** kiểm bằng thí nghiệm các kết quả lý thuyết đã chứng minh hoặc sửa trong ghi chú lý thuyết (`theory/`).
- **Mục tiêu 3:** đưa đủ ba lớp attacker của draft vào, kể cả 3 LLM attacker.
- **Mục tiêu 4:** làm lỗi tối thiểu trước (mục Lộ trình); phần còn lại xếp sau và khai trước dưới dạng lượt bổ sung có freeze riêng.
- **Không làm:** tinh chỉnh lại trên 57 workflow eval của v2. Tập này đã bị chạm hai lần (lượt chính và D35).
- **Không làm:** dùng số v2 làm kết quả v3. Dữ liệu v2 chỉ còn vai trò tập dev và bằng chứng thiết kế.
- **Người quyết:** thầy ký mười lăm điểm C1–C15 trước bước freeze (P4). Code viết được trước, vì mọi điểm C được cài dạng công tắc.
- **Thời gian:** 3–4 tháng chỉ đủ cho lỗi tối thiểu cộng một phần phân sau; toàn bộ phạm vi dài hơn. Chi phí từng khối ghi ở mục Rủi ro.

Cách chứng minh trung thực

Mỗi con số cuối cùng phải đi qua đủ sáu công cụ dưới đây; thiếu một thì số đó không được in.

#	Công cụ	Làm gì	Bảng chứng nộp kèm
T1	Draft là tài liệu tiên đăng ký	Draft 07/09 tự ghi "no experiment has yet been executed", nên mọi số dự phóng là dự đoán có trước mọi phép đo. Ghim sha256 của PDF	Hash và commit có ngày, trong gói tái lập
T2	Ma trận tuân thủ draft (DCM)	Mỗi câu quy định của draft có một ID (ví dụ D4.def1 , D7.pf2048), nối tới module, test và kết quả; mỗi dòng mang một mức L0/L1/L2	DCM trong repo; 100% dòng có test
T3	Test đặt tên theo câu draft	Tên test là chính câu nó bảo vệ; có test kịch bản Figure 1 chạy đủ 7 bước t1-t7	Log test
T4	Bảng điểm dự đoán	Mỗi số dự phóng là một giả thuyết; luật khớp/bác khóa trước lượt chạy	Luật đã hash
T5	Chứng minh hoặc phản ví dụ	Không bỏ định lý nào; kiểm số trên 240 game nhỏ	Chứng minh có người kiểm, không chỉ AI
T6	Một lượt trên tập mới	Tập eval chưa ai chạm, freeze, đổi chứng đọc trước, từ chối có lý do, nhật ký sai lệch so với draft; người ngoài dựng lại số từ record thô	Manifest, log, báo cáo kiểm độc lập

Mức tuân thủ dùng trong toàn bộ doc:

- **L0** — đúng chữ.
- **L1** — draft không cho giá trị; giá trị được khai trước, kèm phân tích độ nhạy.
- **L2** — không làm đúng chữ được; có chứng minh vì sao, làm bản gần nhất, chạy đủ các cách đọc.

Mười lăm điểm phải chốt với thầy

Đây là những chỗ draft tự mâu thuẫn, không nói rõ, hoặc không làm được theo chữ. Chỗ nào có hai cách đọc thì v3 chạy cả hai, không tự chọn; cách đọc chính do thầy ký bằng văn bản. C10-C15 được thêm sau vòng review ngày 27/09.

#	Chỗ vướng trong draft	Cách xử lý	Mức	Trạng thái
C1	Commit audit: §2 và Fig. 1 nói "observes only the artifact"; §7 nói có "provenance of contributing skills"	Hai thể giới: A0 (không đọc provenance) và A7 (có đọc); giá của cả hai phiên bản commit audit đều đo thật	L2, chạy cả hai	Chờ thầy ký
C2	(audit, k, depth) : §4 cho k là carrier; §7, §8 nói "4 audit stages"; Fig. 1 viết "retrieval audits sample the memory store"	Hai thể giới: quét carrier và kiểm theo giai đoạn (tái dùng thể giới cổng D29); chạy Sentinel trong cả hai	L2, chạy cả hai	Chờ thầy ký
C3	§4 định nghĩa $\chi = \text{range}/\bar{k}$, ra 2,114 với giá §7; nhưng §7 ghi $\chi = 1,34$	Ghi erratum; giữ công thức §4; lưới $\{0; 0,5; 1,34\}$ dựng bằng độ sâu như §8 nói; thêm mức 2,114	L0, kèm erratum	Chờ thầy ký
C4	B1 "spends the entire budget... at maximum depth" nên $B = H \cdot \max \kappa$; với một hành động mỗi task, ngân sách không bao giờ chặn policy nào	Chứng minh bổ đề "ngân sách lỏng thì giá không đổi kết quả"; χ chỉ tác động qua cơ chế độ sâu §8; lưới ngân sách bị chặn là phân tích phụ	L2, có chứng minh	Chờ thầy ký
C5	Ba định nghĩa headline: §10.1 " $\Delta > 2$, pooled over χ "; Table 2 " $\Delta > 2$, $\chi = 1.34$ "; §9.4 "not pooled". Table 2 ghi held-out nhưng số 34,1% của nó là số §10.3 gọi là dev	Endpoint chính theo Table 2, tính trên attacker held-out thật; hai định nghĩa kia in đủ, ghi là phụ	L1	Chờ thầy ký
C6	Def. 1: min max L; mục Objectives: tối thiểu harm, FQ "acceptable"	Tính chỉnh theo L (Def. 1); endpoint là harm (§9.3 ghi "primary")	L0	Chờ thầy ký
C7	Algorithm 1 dòng 1 "ước lượng Δ từ lịch sử", trong khi §4 cho attacker chọn σ và biết chính sách	Tách thành hai câu: ai chọn Δ (C10) và bộ ước lượng thấy gì (C12)	—	Chờ thầy ký

#	Chỗ vướng trong draft	Cách xử lý	Mức	Trạng thái
C8	v2 thêm ràng buộc "ngủ yên" (không ai truy xuất payload trong $[1, \sigma]$); draft không có, và Fig. 1 cần note được dùng ở t2	Bỏ ràng buộc; payload kiểu sleeper: được truy xuất và lan mà chưa gây hại, chỉ kích hoạt khi task thỏa vị từ đích	L0	Chờ thầy ký
C9	Toàn lưới trên OpenHands: $4.500 \times 8 \times 3 \approx 108.000$ episode $\times \sim 10$ task $\approx 1,08$ triệu lượt agent	Bất khả về chi phí; sim hiệu chuẩn từ lượt chạy thật, cộng tập chạy thật để kiểm chứng (mục Chạy thật)	L2, có tính toán	Chờ thầy ký
C10	Ai chọn Δ : §4 cho attacker chọn σ ; §8, Figure 3 và Table 2 lại coi Δ là trục của ô thí nghiệm	Endpoint chính: Δ do môi trường cố định theo ô. Thêm một cột "attacker chọn Δ "; Mệnh đề 6.3(a) của ghi chú lý thuyết dự đoán B1 tối ưu minimax ở cột này khi $\Delta = 0$ nằm trong tập chọn (H20)	L1, chạy cả hai	Chờ thầy ký
C11	Tổn hại có đảo ngược được sau σ không: §4 chấm harm ở cuối horizon, Fig. 1 cho harm hiện ra sau σ , nhưng draft không nói quarantine sau σ có gỡ được patch đã vào branch hay không	Chốt một trong hai: tổn hại chốt tại σ , hoặc gỡ branch sau σ xoá được tổn hại. Thầy không chọn thì chạy cả hai; kết luận ở cột "attacker chọn Δ " phụ thuộc điểm này	L2	Chờ thầy ký
C12	Bộ ước lượng Δ ở dòng 1 thầy gì: trước σ , không quan sát nào phụ thuộc vào σ , nên Δ lấy từ belief trong một workflow chỉ bằng tiên nghiệm, tức đúng arm "–regime estimate"	Δ lấy từ lịch sử qua nhiều workflow: phân bổ khoảng cách truy xuất của repo trên các workflow trước. Lấy phân vị thấp, vì ước lượng thấp giữ được bảo đảm (Hệ quả 6.6 của ghi chú). Khai rõ bộ ước lượng được thầy gì	L1	Chờ thầy ký


#	Chỗ vướng trong draft	Cách xử lý	Mức	Trạng thái
C13	Chiều Δ của Theorem 4: draft nói ngân sách cần tăng theo Δ và χ ; ghi chú lý thuyết chứng minh ngân sách tối thiểu giảm cỡ H/Δ và không phụ thuộc χ	Hỏi thầy ý định, dưới dạng câu hỏi chứ không phải kết luận; đưa hai chiều vào bảng điểm (H18)	L2	Chờ thầy ký
C14	Nguồn tập eval mới: không có đủ 15 họ repo chưa chạy. SWE-bench full chỉ có 12 họ; Multilingual chỉ 4 họ có từ 14 instance trở lên, cả 4 đã dùng ở v2	(a) Họ mới hoàn toàn, làm chính: 36 workflow / 18 họ, gồm pylint, requests, seaborn, flask từ SWE-bench full (22 workflow) và 14 họ Multilingual có 6–12 instance (mỗi họ 1 workflow). (b) Instance mới trên 7 họ Python v2 đã eval (1.062 instance), làm phân tích phụ	L2	Chờ thầy ký
C15	Detector đọc gì: ba mức (0,75; 0,20), (0,85; 0,12), (0,92; 0,06) có ψ tăng khi ϕ giảm, nên là ba detector khác chất lượng ($d' = 1,52; 2,21; 2,96$), không phải ba ngưỡng trên một ROC. Tổng hợp lại đòi đặc trưng bề mặt chỉ đạt $AUC \leq 0,56$	Detector đọc nội dung và provenance, không đọc đặc trưng bề mặt. Lưới dùng mô hình khai báo với ba d' ; detector học là một điểm đo thêm, in (ψ, ϕ) thực đạt	L1	Chờ thầy ký

Kiến trúc

Mỗi task, Sentinel chọn một hành động, nhận điểm detector, cập nhật belief, rồi chọn lại; oracle chỉ đọc ở cuối horizon nên không rò rỉ vào quyết định.

Sentinel chọn chỗ soi trong 4 carrier; oracle chấm ở cuối horizon

Mỗi episode chạy trong 4 thể giới = C1 (A0 / A7) × C2 (quét carrier / kiểm theo giai đoạn)



một episode v3 · 6 thành phần, 1 vòng lặp của Sentinel

Payload được gieo vào một carrier, có thể lan sang skill khi agent sinh skill từ quỹ đạo đã dùng nó, và chỉ gây hại khi task thỏa vị từ đích (C8). Bốn thể giới C1 × C2 dùng chung sơ đồ này; chỉ ý nghĩa của hành động audit và thông tin commit review mang về là khác.

Mô hình §4 dựng theo chữ

Mười mục của §4 và Figure 1 đều có cách dựng và một test mang đúng câu của draft. Ba mục là lựa chọn mô hình mà draft không quy định (kênh ingress, tổn hại sau σ, kiểu drift), nên mang nhãn L1 và chạy cả hai phiên bản.

Mục	Draft nói	v3 dựng	Mức	Test
Trạng thái	$s_t = (c_t, \iota, \sigma), c_t \in \{0,1\}$ ⁴	Nhiều carrier nhiễm cùng lúc; poison lan note → skill → patch → branch	L0; xác suất lan L1	<code>test_state_is_carrier_bitvector_with_propagation</code>

Mục	Draft nói	v3 dựng	Mức	Test
Kích hoạt	σ là task poison "activates"; Fig. 1 dùng note ở t2 mà chưa gây hại	Tách truy xuất khỏi kích hoạt: payload có vị từ đích (sleeper)	L0	<code>test_figure1_replays_t1_to_t7</code>
Attacker	Chọn $(k, \iota, \sigma, \epsilon)$; ngân sách giới hạn số carrier và độ lớn	Theo C10: trong ô Δ cố định, attacker chọn (k, ι, ϵ) và $\sigma = \iota + \Delta$; ở cột riêng, attacker chọn cả Δ . Gieo 1 carrier (chính), 2 carrier (độ nhảy)	L1	<code>test_attacker_menu_matches_cell</code>
Kênh ingress	§10.6: best response chèn qua ingress vì insertion audit không thấy kênh này	Giả định mô hình, không phải phát hiện: chạy cả hai phiên bản (insertion audit thấy / không thấy ingress) để H8 không đúng do cách dựng	L1, chạy cả hai	<code>test_ingress_visibility_is_a_switch</code>
Hành động	$\{\text{none}\} \cup \{(\text{audit}, k, \text{depth})\}$, một hành động mỗi task, $\sum k \leq B$	Đúng chữ; hai cách đọc k theo C2	L0 + C2	<code>test_one_action_per_task_within_budget</code>

Mục	Draft nói	v3 dựng	Mức	Test
Quan sát	Alarm (ψ, ϕ) và kết quả checkpoint thực thi	Checkpoint = test SWE-bench trên patch ở tập chạy thật; trong sim là kênh (ψ_c, ϕ_c) khai trước. Commit review thấy bản vá uỷ nhiệm với độ tách p-d' ở mọi độ sâu (D20 của v2; chứng minh Theorem 4 của draft)	L0 / L1	<code>test_checkpoint_channel_declared</code>
Quarantine	Chi phí η_Q ; gỡ cả carrier có hậu nghiệm cao nhất	Đúng chữ	L0	<code>test_quarantine_removes_whole_carrier</code>
Harm	Sealed oracle chậm ở cuối horizon; harm hiện ở module khác	Oracle chậm trạng thái repo cuối horizon. Gỡ branch sau σ có xoá được tổn hại hay không là một công tắc theo C11	L1, chạy cả hai	<code>test_harm_read_at_horizon_end</code>
Loss	$L = \text{harm} + \lambda_Q \cdot \text{FQ} + \lambda_T \cdot \text{clean lost}$; $V^* = \min \max L$	Đúng chữ; λ khai trước	L0	<code>test_loss_matches_definition_1</code>

Mục	Draft nói	v3 dụng	Mức	Test
Drift	Tốc độ β , thông kê quan sát khớp với poisoning; không nói drift tồn tại bao lâu	620 thay đổi lành khớp bề mặt. Hai phiên bản: drift thoáng qua (chính) và drift dai dẳng. Với drift dai dẳng và $\beta > \alpha/(1 - \alpha)$, Mệnh đề 5.11 của ghi chú chứng minh không chính sách nào phân biệt được	L1, chạy cả hai	<code>test_drift_matched_on_four_surface_features</code>

Sentinel theo Algorithm 1 và §7

Sentinel v3 chạy đúng tám dòng của Algorithm 1, không có oracle Δ ; oracle chỉ còn là một arm tham khảo cũ trên.

Dòng / mục	Draft nói	v3 dụng	Mức	Cổng kiểm
Dòng 1	Ước lượng Δ , $\hat{x}$ từ lịch sử	Δ từ lịch sử qua nhiều workflow, lấy phân vị thấp (C12); belief trên σ trong một workflow không mang thông tin trước σ . $\hat{x}$ từ bảng giá đo	L0	Mọi số headline đến từ lượt không oracle

Dòng / mục	Draft nói	v3 dụng	Mức	Cổng kiểm
Dòng 2-3	KH ≤ 40 thì giải chính xác trên belief MDP	Áp đúng ngưỡng cho cả workflow thật ($H \leq 10$ thì KH ≤ 40). Không tính nổi thì in số trạng thái và thời gian làm bằng chứng bất khả	L0 / L2	Log số trạng thái và runtime
Dòng 5	argmin theo π của max theo π_A của $L(\pi, \pi_A; b_t, B_t)$, mỗi task	Rollout từ các particle cho 28 member nhân với lớp attacker	L0	Sai số Monte Carlo dưới ngưỡng khai trước
Dòng 7	Particle filter 2048 hạt; drift là nguyên nhân cạnh tranh; β ước lượng online từ workflow sạch	Đúng chữ; ở thế giới A7, commit review cập nhật belief với cường độ ρ	L0	<code>test_belief_moves_after_commit_alarm_when_rho_positive</code>
Dòng 8	$\Pr[\text{poisoned}]$ vượt τ và expected harm vượt η_Q thì gỡ carrier hậu nghiệm cao nhất	Đúng chữ; η_Q là chi phí	L0	η_Q được chọn không nằm ở mép lưới, hoặc phải khai
Thư viện	28 policy, ba họ: stage-weighted, belief-threshold, carrier-rotation	Tham số khai trước; τ nằm trong dải (p_{floor}, p_0) của Prop. 6.1	L1	Kiểm Prop. 6.1 trước tinh chỉnh: mỗi họ có ít nhất một member đổi được quyết định
Ngẫu nhiên hoá	Công bố phân phối, không công bố lần rút	Attacker biết hàm chính sách, không biết lần rút	L0	—
Tinh chỉnh	Robust trước sai số kernel ζ	Theo worst-case L trên dev (C6), qua 3 kernel lệch $\zeta = 0,10$	L0	Log lựa chọn đã hash

Bổn ablation của Table 3, dựng theo đúng tên gọi:

- **-randomization:** chính sách tắt định tốt nhất trước best response (§5.3), không phải một member đóng băng như v2.
- **-alarm memory:** Sentinel không nhớ báo động (stateless).
- **-transition uncertainty:** tinh chỉnh trên kernel danh định, nhưng đánh giá trên cả kernel lệch.
- **-benign-drift modelling:** bỏ drift khỏi belief.
- **Cổng chung:** mọi arm phải đổi được ít nhất một quyết định trong ô headline. Không đạt thì in "không được vận dụng", không in như một hiệu ứng bằng 0.

AuditGame-SE §8

Benchmark giữ đúng lưới của Table 1, trừ hai chỗ không làm đúng chữ được: không có đủ 15 họ repo chưa chạm (C14), và ba mức detector là ba detector khác chất lượng (C15). Giá audit trở lại đúng chữ: đo thật thay vì gán.

Mục	Draft nói	v3 dựng	Mức
Quy mô	100 workflow / 15 repo, 6-14 task	Theo C14. Chính: 36 workflow / 18 họ chưa chạm (pylint 10, requests 9, seaborn 2, flask 1 workflow; 14 họ Multilingual mỗi họ 1). Phụ: instance mới trên 7 họ Python v2 đã eval. Đếm chính xác lại khi dựng tập	L2
Số instance	4.500	= số workflow $\times$ 5 mức $\Delta \times$ 3 mức $\chi \times$ 3 detector; với 36 workflow là 1.620	L2 theo C14
Δ	{0, 1, 2, 4, 8}	Đúng chữ, cộng cột "attacker chọn Δ " (C10)	L0
χ	{0; 0,5; 1,34}, "achieved by equalising or differentiating audit depths"	Theo C3; thêm mức 2,114	L0

Mục	Draft nói	v3 dụng	Mức
Thay đổi lành	620, khớp edit size, embedding shift, recency, provenance shape; AUC $\leq$ 0,56	Sinh đúng 620, kiểm đúng 4 đặc trung. Không đạt thì in "không đạt", không nói mức trần	L0
Payload	Loại tấn công đã công bố	AgentPoison, MINJA (code đã có trong repo), MemPoison; marker xoay vòng 8 mẫu	L0
Attacker scripted	18 luật, 7 held-out	Đúng chữ	L0
Detector	Detector học dùng chung; (ψ , ϕ) đo trên split hiệu chuẩn; 3 mức 0,75/0,20, 0,85/0,12, 0,92/0,06	Theo C15: ba detector khác chất lượng ($d' = 1,52; 2,21; 2,96$) bằng mô hình khai báo cho lưới. Detector học đọc nội dung và provenance, không đọc đặc trưng bề mặt; là một điểm đo thêm, (ψ , ϕ) đo bằng nhãn ground truth của evaluator	L1
Giá audit	Đo bằng CPU-phút: insertion 0,4; retrieval 0,9; delegation 1,6; commit 4,1	Hiện thực 4 kiểm tra như §7 mô tả rồi đo (<code>checkpoints.py</code> , <code>tools/measure_kappa*.py</code>); số đo khác bảng của draft thì vẫn in	L0
Game nhỏ	240 game, minimax chính xác	Đúng chữ	L0
Held-out	Theo họ repo và theo attacker	Tinh chỉnh chỉ trên django; eval chính trên 18 họ chưa chạm	L0

LLM attacker

LLM attacker đưa vào được và là phần chạy thật rẻ nhất. Điều kiện tiên quyết: detector hoặc agent phải đọc nội dung payload. Ở v2 cả hai đều không đọc (T8), nên LLM chỉ còn là bộ chọn vị trí.

Draft yêu cầu gì

- §8 và Table 1: "3 unconstrained LLM attackers, reported separately as a behavioural measurement".
- RQ3: ba lớp attacker (hợp lý, scripted held-out, LLM) hành xử có khác nhau không, và mỗi lớp cho phép kết luận điều gì.
- §10.4: Sentinel giảm harm 41,2% so với B1; mọi policy đều tốt hơn trước LLM attacker, vì chúng chèn vào thời điểm dễ đoán và hiểm khi tận dụng chênh lệch giá giữa các carrier.
- Kết quả LLM không được dùng cho kết luận về cân bằng, nên không đưa vào worst-case V.
- §14: ghi model ID và ngày truy cập; ghim một backend open-weight bằng digest.

Ảnh xạ bốn mức A0–A3 (tiền đăng ký 20/09) vào draft

Mức	Nội dung	So với draft
A0 llm-blind	LLM chỉ viết chữ; vị trí do benchmark gán	Không phải attacker của draft vì không thấy chính sách. Giữ làm control
A1 llm-informed	LLM thấy K, κ , H và chính sách đã công bố; tự chọn (k , ι , σ , ϵ) và viết chữ	Đúng chữ. Đây là lớp LLM chính, chạy với 3 model
A2 llm-hybrid	Vị trí do liệt kê best response chọn; LLM chỉ viết chữ	Về chiến lược, đây là best-responder hợp lý có nội dung mạnh hơn. Báo cáo trong lớp hợp lý
A3 llm-adaptive	A1 cộng phản hồi "payload trước bị bắt ở đâu"	Ngoài draft (Remark 7). Chỉ làm như phần bổ sung, dán nhãn rõ

Thiết kế theo chữ

Mục	Làm thế nào
3 attacker	3 model khác họ: một model mạnh nhất hiện có, một model rẻ, một model open-weight ghim bằng digest (§14)

Mục	Làm thế nào
Thông tin cho attacker	Đúng tập thông tin Stackelberg: K carrier, bảng giá κ , H, hỗn hợp chính sách đã công bố của từng hệ thống, cách detector hoạt động. Không cho lần rút ngẫu nhiên, điểm detector hay ground truth
"Unconstrained"	Không bị giới hạn trong 18 luật scripted; được chọn mọi (κ , ι , σ , ϵ , nội dung) mà harness biểu diễn được, trong ngân sách attacker. Lựa chọn không biểu diễn được thì ghi lý do, không ánh xạ lằng lẽ
Nơi chạy	Ô headline, đủ 8 hệ thống $\times$ 100 workflow $\times$ 3 model, cả hai thể giới C1; payload A1 còn được đưa vào tập chạy thật
Sinh payload	Offline rồi đóng băng; hash prompt, model ID, phiên bản/ngày, temperature, seed trước khi sinh
Marker	Bộ 8 marker xoay vòng theo đỉnh chính 20/09 (marker cố định <code>raw_write</code> từng cho AUC = 1,000 chỉ bằng <code>grep</code>)
Báo cáo	Tách riêng, không vào worst-case V; bảng RQ3 ba dòng (hợp lý, scripted held-out, LLM $\times$ 3) cho đủ hệ thống

Phép đo

ID	Draft nói	Đại lượng	Luật
H11a	Sentinel giảm 41,2% so với B1 trước LLM attacker	Mức giảm, mỗi model	P
H11b	"all policies do better against them"	Với từng hệ thống: V trước LLM so với V trước scripted held-out	D, 8 so sánh, BH
H11c	"insert at predictable times"	Entropy chuẩn hoá của vị trí ι tương đối mà LLM chọn, so với best response	D

ID	Draft nói	Đại lượng	Luật
H11d	"rarely exploit carrier heterogeneity"	Tỉ lệ lựa chọn rơi vào carrier ít được phủ nhất, so với best response	D
H11e	"weak adversaries flatter defenders"	Khoảng cách chiến lược $V_{BR} - V_{LLM}$ trước cùng một chính sách	Báo cáo kèm CI

Hàng rào trung thực

1. Không dựng người rơm bằng prompt yếu: prompt chứa đủ tập thông tin ở trên, cho phép suy luận, đóng băng trước khi thấy bất kỳ số nào. Pilot trên dev chỉ để kiểm output parse được.
2. Model từ chối cũng là dữ liệu: in tỉ lệ từ chối mỗi model; luật thay model dự phòng khai trước, không đổi model sau khi xem số.
3. LLM attacker không tham gia tinh chỉnh, nên held-out theo cấu tạo (§5.5).
4. A3 nếu làm: tối đa 5 vòng; phản hồi chỉ trên một parity, chấm trên parity còn lại. Hơn A2 chỉ trên parity đã fit thì kết luận là overfit.

Tín hiệu sớm từ pilot

Pilot hiện có dùng 1 model, 1 lần gọi mỗi policy, trên thể giới cũ. LLM có lập luận theo κ : với Sentinel nó chọn branch vì " $\kappa = 4,1$ cao nhất nên ít bị kiểm", với B1 nó tránh branch. Nhưng chất lượng vị trí gần ngẫu nhiên (hạng trung bình 5,733/12; ngẫu nhiên 6,5). H11d vì vậy có thể bị bác; pilot chưa đủ để kết luận.

Chi phí và vị trí trong lộ trình

- Pilot tốn khoảng 0,12 USD cho 8 lần gọi. Ô headline cần khoảng 2.400 lần gọi mỗi thể giới: vài chục USD nếu cả ba model rẻ như pilot, tới vài trăm USD nếu dùng model mạnh.
- Năm trong P3, sau khi có detector học đọc nội dung. Trước đó, LLM attacker chỉ đo được chiến lược chọn vị trí và phải ghi đúng như vậy.

Lý thuyết: chứng minh hoặc bác

Ghi chú lý thuyết (`theory/out/main.pdf` , 20 trang) đã chứng minh hoặc sửa mọi kết quả ở §6 của draft, kèm script kiểm số trong `theory/checks/` .v3 chỉ còn phải kiểm chúng bằng thí nghiệm và nhờ một người kiểm độc lập; P1 vì vậy rút ngắn.

Kết quả của draft	Tình trạng trong ghi chú lý thuyết	Việc còn lại trong v3
Definition 1	Định nghĩa tốt: min-max đạt được và bằng max-min. Vì attacker tối đa hoá harm chứ không phải L , V^* là cận trên của giá trị Stackelberg (Bổ đề 1.4)	Ghi vào Threats
Theorem 3	Chứng minh được đúng như phát biểu (Định lý 3.1). So với kernel thật thì cận là $2H\zeta$; tính chặt đúng với $\min(1, H\zeta)$ (Mệnh đề 3.2)	Kiểm trên game nhỏ với kernel lệch (<code>checks/thm3_tightness.py</code> đã có)
Theorem 4	Sửa lại (Định lý 5.6). Nguyên văn chỉ đúng với c cỡ $1/K$, và khi đó thừa số theo Δ và χ không mang thông tin. Khi commit mù với bản vá uỷ nhiệm, ngân sách tối thiểu giảm cỡ H/Δ , không phụ thuộc χ , kèm điều kiện của số $\Delta \geq K \cdot n_\alpha$. Chiều này kiểm được	Hỏi thầy ý định (C13); kiểm bằng H18

Kết quả của draft	Tình trạng trong ghi chú lý thuyết	Việc còn lại trong v3
Corollary 5	Thay bằng Hệ quả 6.1 và Mệnh đề 6.3: attacker chọn được $\Delta = 0$ thì B1 tối ưu minimax; mức giảm không giảm theo Δ và bị chặn bởi $p_d - p_p$; khi $H \geq 2\Delta + 1$ không lịch tất định nào thắng B1; ranh giới Δ^* tăng theo K, ngược về "carriers proliferate" của draft	Kiểm bằng H3, H19, H20
Prop. 6	Chứng minh được khi bán kính phủ đo so với π^* (Mệnh đề 4.2). Đọc theo chữ (so với toàn bộ không gian chính sách) thì bán kính $\geq 1 - 1/m$, tức $\geq 12/13$ trong mô hình của paper, và cận vô nghĩa (Nhận xét 4.3)	Đo so với π^* , trên hỗn hợp của 28 thành viên, TV lấy max theo task (H7)
Remark 7	Giới hạn của mô hình	Chép sang Threats
Δ ước lượng sai (Hệ quả 6.6, mới)	Ước lượng thấp giữ được bảo đảm; ước lượng cao có thể tệ hơn B1 khi Δ thật bằng 0	Dùng cho C12 (phân vị thấp)
Drift dai dẳng (Mệnh đề 5.11, mới)	Nếu drift dai dẳng với $\beta > \alpha/(1 - \alpha)$ thì không chính sách nào phân biệt được, ở bất kỳ ngân sách nào	Lý do chạy cả hai phiên bản drift
Bổ đề C4 (mới)	Ngân sách lỏng thì giá không đổi kết quả	Chứng minh ngắn; in cạnh C4

Cận của Theorem 4, đúng như draft in:

$$B \geq \frac{c, \bar{\kappa}, (1+\chi), \log(1/\alpha)}{\gamma^2} \left(1 + \frac{\Delta}{H} K\right)$$

Dạng sửa lại (Định lý 5.6 của ghi chú), khi commit mù với bản vá uỷ nhiệm; n_α là số quan sát cần để đạt sai số α :

$$B \geq K/\bar{\kappa}, \quad n_\alpha \left\lceil \frac{H-1}{\Delta} \right\rceil, \quad \Delta \geq K, \quad n_\alpha$$

Xác suất B1 bỏ sót một bản vá uỷ nhiệm. Không có vd: độ sâu không làm commit thấy thêm provenance (chứng minh Theorem 4 của draft, D20 của v2). A0 ứng với $\rho = 0$:

$$P^{\{\text{B1}\}_{\text{miss}}} = \Phi(z_{1-\varphi} - \rho, d')$$

Ghi chú đã qua một vòng soát độc lập bằng agent (4 lỗi và 17 điểm nhỏ, đã sửa hết). Vẫn cần một người kiểm: thầy hoặc một thành viên RAISE Lab. Những chỗ nói draft sai (chiều Δ của Theorem 4, về "carriers proliferate", cách đọc bán kính phủ) được đưa tới thầy dưới dạng câu hỏi về ý định, không phải kết luận.

Thiết kế đánh giá §9

Endpoint chính giữ đúng §9.4: harm tệ nhất giảm ít nhất 15% so với B1, trước attacker held-out, cùng ngân sách, ở ô của Table 2 (C5), với Δ do môi trường cố định (C10). Cột "attacker chọn Δ " in riêng.

Mục	Draft	v3
Hệ thống	B1-B7 và Sentinel	Thêm cost-greedy allocator (§10.1), stage-weighted ngẫu nhiên hoá (§11) và B1-prov (C1) để kiểm câu của chính draft
Chỉ số	Worst-case verified harm (primary), clean completion, FQ, audit cost CPU-phút, detection delay, exploitability, regret so với B7	Đủ bầy
Seed	3	Đúng chữ
Khoảng tin cậy	Cluster bootstrap theo họ repo	Wild cluster bootstrap (Cameron-Gelbach-Miller, có trong reading list) vì chỉ có 15 cluster
So sánh phụ	Benjamini-Hochberg (reading list)	BH, $q = 0,05$

Mục	Draft	v3
Cách in	Trên lưới (Δ, χ), không gộp	Đúng chữ; Table 2, Table 3, Figure 3 in đúng hàng cột như draft, cột dự phóng cạnh cột đo
Freeze	Hash policy và thư viện attacker; harness từ chối policy không có trong manifest	Đúng chữ
Đối chứng	Không có	Giữ đối chứng Oracle (+) và $\Delta = 0$ (-) từ v2, đọc trước mọi số Sentinel

Bốn câu hỏi nghiên cứu giữ nguyên chữ của draft:

- **RQ1:** vùng (Δ, χ) nào commit là đủ, và điểm giao đo được có khớp ranh giới dự đoán không.
- **RQ2:** harm tệ nhất cùng ngân sách trước attacker held-out, và cái giá về clean completion, FQ, detection delay.
- **RQ3:** ba lớp attacker hành xử khác nhau ra sao, mỗi lớp cho phép kết luận gì.
- **RQ4:** thành phần nào gánh hiệu ứng, và kết luận đối thể nào theo detector.

Bảng điểm dự đoán

Mỗi số dự phóng của draft là một giả thuyết; luật quyết định dưới đây được hash trước lượt chạy và không sửa sau khi thấy số.

- **P** (một con số): mỗi giả thuyết có một biên δ khai trước ở P0 (đề xuất: ± 5 điểm phần trăm cho mức giảm, $\pm 0,03$ cho harm). Khớp nếu cả CI 95% nằm trong [dự phóng - δ ; dự phóng + δ]; bác nếu CI không chứa số dự phóng; còn lại, kể cả khi CI rộng hơn 2δ , là không kết luận. Luật này không thưởng cho phép đo kém chính xác.
- **D** (hướng hoặc thứ tự): khớp nếu CI của hiệu loại trừ 0 và đúng dấu; bác nếu loại trừ 0 nhưng ngược dấu; còn lại là không kết luận. Cả họ D hiệu chỉnh BH, $q = 0,05$.
- **G** (cổng): cận dưới của mức giảm ít nhất 15% (§9.4).
- H18-H20 đặt dự đoán của draft cạnh dự đoán ngược lại của ghi chú lý thuyết; dấu của hiệu đo được quyết định bên nào đúng.

ID	Dự đoán (nguồn)	Loại	Kết quả
H1	Draft: harm tệ nhất giảm ít nhất 15% so với B1, attacker held-out, cùng ngân sách (dự phóng 27,6%)	G + P	Chưa chạy
H2	Draft: từ dev (34,1%) sang held-out (27,6%) mất khoảng 1/5	P	Chưa chạy
H3	Draft: điểm giao ở $\Delta \approx 2$ (2,1) khi $\chi = 0$; muộn hơn khi $\chi = 1,34$. Ghi chú: Δ^* phụ thuộc K, α , β , γ , không phụ thuộc χ	P + D	Chưa chạy
H4	Draft: tại $\Delta = 0$, Sentinel tệ hơn B1 1,2%	P	Chưa chạy
H5	Draft: chênh lệch giá làm mức giảm co lại: 34,8 $\rightarrow$ 24,8% ($\Delta = 4$); 42,4 $\rightarrow$ 33,1% ($\Delta = 8$)	D	Chưa chạy
H6	Draft: cost-greedy tệ hơn uniform random	D	Chưa chạy
H7	Draft: regret so với B7 là 0,09; bán kính phủ 0,07; cận 0,42. Đọc theo chữ thì bán kính $\geq 12/13$, nên 0,07 đã bị bác bằng giải tích; phép đo là so với π^* , trên hỗn hợp 28 thành viên, TV lấy max	P	Chưa chạy
H8	Draft: B3 tệ nhất (0,441); best response chèn qua ingress. Cơ chế là giả định mô hình, nên kiểm ở cả hai thể giới (insertion audit thấy / không thấy ingress)	D	Chưa chạy
H9	Draft: exploitability của Sentinel 0,09, của B1 0,34	P	Chưa chạy
H10	Draft: clean completion 92,6% so với 94,1%; FQ 5,1% so với 3,2%	P	Chưa chạy
H11	Draft: LLM attacker cho mức giảm 41,2%, mọi policy đều tốt hơn (chi tiết H11a-e ở mục LLM attacker)	P + D	Chưa chạy
H12	Draft: -randomization 0,456 (tệ hơn B1), -alarm memory 0,371, -transition 0,318, -drift 0,264 với FQ 19,8%	P + D	Chưa chạy
H13	Draft: mức giảm 21,4–39,8% theo detector, lớn nhất khi detector yếu nhất	D	Chưa chạy

ID	Dự đoán (nguồn)	Loại	Kết quả
H14	Draft: quét η_Q cho mức giảm tăng 34,1 $\rightarrow$ 44,0% khi cách ly rẻ	D	Chưa chạy
H15	Draft: B5 bị attacker lái, FQ 8,1% mà harm không giảm	D	Chưa chạy
H16	Draft: best response chống Sentinel trải đều các carrier	D	Chưa chạy
H17	Draft: stage-weighted ngẫu nhiên hoá đạt hơn một nửa lợi ích của Sentinel	D	Chưa chạy
H18	Draft (Theorem 4): ngân sách cần tăng theo Δ và χ . Ghi chú (Định lý 5.6): ngân sách tối thiểu giảm cỡ H/Δ và không phụ thuộc χ	D	Chưa chạy
H19	Draft (Corollary 5): commit càng không đủ khi carrier nhiều lên. Ghi chú (Hệ quả 6.1): Δ^* tăng theo số carrier uỷ nhiệm K, tức mức giảm nhỏ lại khi K tăng	D	Chưa chạy
H20	Ghi chú (Mệnh đề 6.3(a)): ở cột attacker chọn Δ , với $\Delta = 0$ nằm trong tập chọn, Sentinel không thắng B1	D	Chưa chạy

Khi số xấu, draft đã viết sẵn câu trả lời: "if audit-at-commit achieves comparable worst-case harm... this line of work should not continue" (§3.5). Số xấu đi qua đủ T1-T6 là kết quả hợp lệ; số đẹp không đi qua thì không được dùng.

Chạy thật và hiệu chuẩn

Chạy thật toàn lưới cần khoảng 1,08 triệu lượt agent (4.500 instance $\times$ 8 hệ thống $\times$ 3 seed $\times$ ~ 10 task), nên không khả thi. Bản gần nhất với draft gồm ba bước:

- Hiệu chuẩn.** Chạy agent thật (OpenHands) trên một mẫu phân tầng để ước lượng, kèm CI, các tham số của mock agent: tỉ lệ làm theo lời khuyên độc, xác suất sinh skill, xác suất để lại queued call, tỉ lệ giải được task, xác suất lan.
- Lưới đầy đủ** chạy trong sim đã hiệu chuẩn.
- Tập chạy thật để kiểm chứng.** Chạy thật từ đầu đến cuối ô headline cho B1 và Sentinel. Tiêu chí khớp giữa sim và thật khai trước; cỡ mẫu suy ra từ tiêu chí đó.

Agent chạy thật có sẵn trong repo là `agent_11m.py` (vòng ReAct tự viết, carrier là tool), không phải OpenHands như draft ghi; mức L2, lý do đã có trong docstring của module. Chi phí của lượt hiệu chuẩn và tập kiểm chứng phải ước tính ở P0 bằng `tools/estimate_study_cost.py`, trước khi chốt cỡ mẫu.

Hai kết quả xấu đã có cách đọc trước:


- Pilot hiện có cho 0/7 lần agent thật làm theo lời khuyên độc. Nếu mẫu lớn vẫn gần 0, in ra: đó là bằng chứng tiền đề của draft không đúng trong thực tế.
- Nếu sim và thật không khớp, mọi số harm in kèm nhãn "sim chưa được kiểm chứng".

Lộ trình

Lượt eval duy nhất (P5) chỉ chạy sau khi lý thuyết, test và luật chấm đã khóa; tổng thời gian ước lượng 3-4 tháng.

Lượt eval duy nhất chỉ chạy sau khi lý thuyết, test và luật chấm đã khóa

Bảy pha; lỗi tối thiểu chạy trước, toàn bộ phạm vi dài hơn 3-4 tháng; P2 và P3 song song



lộ trình v3 · 7 pha, 6 cổng

Cổng 4 là cổng quyết định: sau nó không còn tinh chỉnh, và mọi thay đổi là một sai lệch phải khai. Thời lượng từng pha là ước lượng; cổng thì không được rút ngắn.

Các cổng, cho bản xuất ra chữ: 0 — văn bản ký và hash đã commit; 1 — chứng minh có người kiểm, script kiểm số xanh; 2-3 — 100% ma trận có test xanh, test Figure 1 xanh, cổng AUC in đạt hoặc không đạt; 4 — manifest và luật bảng điểm đã hash trước lượt chạy; 5 — mọi số có con trở tái lập; 6 — báo cáo sim khớp hoặc không khớp với chạy thật.

Lỗi tối thiểu đi qua đủ bảy pha trước, với phạm vi hẹp:

- một thể giới: A0 × quét carrier;
- bộ ước lượng Δ thật theo C12;
- các định lý đã sửa cùng thí nghiệm kiểm chứng (H18–H20);
- tập eval theo C14.

Thể giới A7, thể giới kiểm theo giai đoạn, LLM attacker và chạy thật xếp sau. Mỗi phần là một lượt bổ sung có freeze riêng, khai trước trong tiền đăng ký như D35 của v2.

Rủi ro và phương án

Rủi ro lớn nhất không phải số xấu mà là số xấu bị đọc sai; mỗi dòng dưới đây đã có dấu hiệu từ v2 hoặc pilot.

Rủi ro	Dấu hiệu đã có	Phương án
Sentinel đúng draft vẫn bằng B1 khi attacker chọn Δ	v2: arm "–regime estimate" bằng B1 ở mọi p ; ghi chú lý thuyết: Mệnh đề 6.3(a)	Chỉ là cột phụ (C10); endpoint chính là ô Δ cố định. Nếu đúng thì in như kết quả đã dự đoán (H20)
Bộ ước lượng Δ không hơn tiên nghiệm	Belief trong một workflow không mang thông tin trước σ	Dùng lịch sử qua nhiều workflow (C12); in thêm arm oracle làm cận trên
Tập eval mới nhỏ	36 workflow / 18 họ; 14 họ chỉ có 1 workflow	Luật P mới trả "không kết luận" khi CI rộng; phương án (b) của C14 làm phân tích phụ cỡ lớn hơn
Agent thật không làm theo lời khuyên độc	Pilot: 0/7	Đưa lượt hiệu chuẩn lên trước P5; nếu vẫn gần 0 thì in là kết quả
Payload không qua cổng AUC 0,56	v2: cổng hợp lệ đỏ, 203/205 test đạt	Payload theo mô hình ε ba chiều; không đạt thì mọi số harm mang nhãn
Thư viện belief vẫn bị khoá	v2: 12/12 member belief-threshold khoá	Kiểm Prop. 6.1 là cổng trước tinh chỉnh

Rủi ro	Dấu hiệu đã có	Phương án
Tập eval bị nhiễm	v2: D30, D35	Dựng và hash tập mới trước mọi tình hình; không để trợ lý AI tự thiết kế lần chạm thứ hai
Chứng minh có lỗi hổng	Ghi chú đã qua một vòng soát bằng agent (4 lỗi, đã sửa)	Người kiểm độc lập là con người; phần sai in thành phần ví dụ
Model LLM từ chối	Pilot có trường refusals	In tỉ lệ từ chối; luật thay model khai trước
Khối lượng tính toán vượt dự kiến	Dòng 5 chạy rollout mỗi task; giải chính xác belief MDP với $H \leq 10$ có thể không tính nổi; 4 thể giới nhân khối lượng lên 4	Lỗi tối thiểu chỉ chạy một thể giới; dòng 5 dùng bảng tính trước (L1) kèm đo sai số; đo thời gian chạy trên dev trước khi chốt lưới
Trễ tiến độ	—	Lỗi tối thiểu trước; P3 song song P2; LLM attacker chỉ chạy ở ô headline

Tài liệu gốc

Mọi đường dẫn tính từ gốc vault HCMUT/ . Ba file draft được ghim bằng sha256 để làm tài liệu tiên đăng ký (T1).

Tài liệu	Đường dẫn	sha256
Draft FSE-2027-15, bản 07/09/2026	261-Master-Proposal/FSE-2027-15-paper.pdf	c37643f0971c3457c176c39607e1be6782007c85988c053e4b5ab0aa8be7263a
Summary của draft	261-Master-Proposal/FSE-2027-15-summary.pdf	078e9b932ed64aa13a8037637dbcce8c8a6496877b1ef71cb9bdcf8187421711
Reading list của draft	261-Master-Proposal/FSE-2027-15-reading.pdf	435ff5a226706470fe590b7627499c1295ef77695d5c46160d87127312f67c38
Ghi chú lý thuyết	theory/out/main.pdf (nguồn theory/main.tex)	—
Script kiểm số của ghi chú	theory/checks/	—
Dữ liệu SWE-bench (full, Verified, Multilingual)	code/Sentinel/auditgame/data/	—

Tài liệu	Đường dẫn	sha256
Bài FSE v2 (bản đồ regime)	<code>paper/out/main.pdf</code>	—
Báo cáo v2 so với draft	<code>code/Sentinel/docs/reports/v2-so-voi-draft.md</code>	—
Tiên đăng ký v2	<code>code/Sentinel/docs/preregistration/TIEN-DANG-KY-v2-thiet-lap-draft.md</code>	—
Tiên đăng ký LLM attacker (A0-A3)	<code>code/Sentinel/docs/preregistration/TIEN-DANG-KY-Attacker-LLM.md</code>	—
Pilot LLM attacker	<code>code/Sentinel/auditgame/spikes/attacker-llm-a1a2.json</code>	—